

Übung 03

CNN mit **Keras** in **Python**: Erkennung mit eigenen Bildern

INFI-IS

5xHWII

November 14, 2025

Abgabetermin: lt. Moodle
Übungsleiter: Albert Greinöcker



Ziel der Übung:

- Kennenlernen RNN und Erweiterungen wie LSTM und GRU in Keras
- Vorbereiten von eigenen Texten für die Verwendung von RNN
- Interpretation der Ergebnisse

1 Vorbereitung

Installation

- KERAS sollte schon für Übung 02,03 installiert sein

Folgende Skripte aus unserem github-Projekt `machine_learning_examples` könnten dabei hilfreich sein:

- `ex_05_rnn_imdb.py`: Ein Beispiel für eine Sentimentanalyse mit Filmkritiken (positiv/negativ) der Internet Movie Database
- `ex_05_rnn_custom_data.py`: Wie kann man die Texte so vorbereiten dass sie für eine RNN geeignet sind.
- `ex_05_rnn_reuters_categories.py`: Grundsätzliches Laden der Daten und die Kategorien als Liste

2 REUTERS-Kategorien

Ein RNN-Modell (z. B. LSTM oder GRU) soll entwickelt werden, dass Nachrichtenartikel aus dem Reuters-Datensatz automatisch einer Themenkategorie zuordnet. Der Datensatz ist schon vorhanden und in KERAS aufbereitet (siehe `ex_05_rnn_reuters_categories.py`):

```

1 from tensorflow.keras.datasets import reuters
2
3 # Nur die 10.000 häufigsten Wörter verwenden
4 (x_train, y_train), (x_test, y_test) = reuters.load_data(num_words=10000)
5
6 print(len(x_train), "Trainingsbeispiele")
7 print(len(x_test), "Testbeispiele")
8 print(max(y_train), "Kategorien")

```

Er hat den folgenden Aufbau:

```

8982 Trainingsbeispiele
2246 Testbeispiele
45 Kategorien

```

KERAS bietet leider keine Möglichkeit die Kategorie-Namen auszulesen, deshalb hier eine Liste:

```

1 label_names = [
2     "cocoa", "grain", "veg-oil", "earn", "acq", "wheat", "corn", "crude",
3     "money-fx", "interest", "ship", "trade", "reserves", "cotton", "coffee",
4     "sugar", "gold", "tin", "strategic-metal", "livestock", "retail", "ipi",
5     "iron-steel", "rubber", "heat", "jobs", "lei", "bop", "carcass",
6     "money-supply", "alum", "oilseed", "meal-feed", "cpi", "housing",
7     "rubber", "zinc", "nickel", "orange", "pet-chem", "dlr", "gas", "silver",
8     "wpi", "strategic-reserves", "wheat-germ"
9 ]
10
11 print(f"Beispielklasse: {y_train[0]} {label_names[y_train[0]]}")

```

Wie hat sich die Qualität der Klassifikation durch die Erhöhung der Kategorien verändert?

3 Aufbereiten von bestehenden Texten

Kaggle ([kaggle.com](https://www.kaggle.com)) bietet eine Menge von Datensätzen an, die für solche Klassifikationen gut geeignet sind. Hier ein paar Beispiele:

- Text Document Classification Dataset: <https://www.kaggle.com/datasets/sunilthite/text-document-classification-dataset>. Enthält ca. 2.225 Textdokumente in 5 Kategorien (Politik, Sport, Technik)
- Ecommerce Text Classification <https://www.kaggle.com/datasets/saurabhshahane/ecommerce-text-cl>
- ArXiv Multi-Label Text Classification Datasets (63MB) <https://www.kaggle.com/datasets/kelixirr/arxiv-multi-label-text-classification-datasets>. Wissenschaftliche Papers

Hinweis: Für den Download lässt sich kagglehub gut verwenden, weil gleich in Python integriert (code wird beim Download angeboten)